

Statystyczna analiza danych

dr Marcin Woźniak

woz@amu.edu.pl

Literatura

- Statystyczna analiza danych z wykorzystaniem programu R, red. M. Walesiak, E. Gatnar, PWN 2012.
- **P. Biecek, Przewodnik po pakiecie R, Oficyna GIS, 2014.**
- StatSoft (2006). Elektroniczny Podręcznik Statystyki, Krakow, WEB:
<http://www.statsoft.pl/textbook/stathome.html>
- B. Everitt, T. Hothorn, A Handbook of Statistical Analyses Using R, Taylor & Francis 2010.

Warunki zaliczenia

- Obecność
- Dwa projekty zaliczeniowe na min. 3
- Aktywność na zajęciach

Zasady

- Nie używamy telefonów komórkowych
- Pracujemy na laptopach/desktopach
- Pracujemy rzetelnie
- Słuchamy siebie nawzajem
- Skrypty
- Staramy się nie spóźniać

Plan ćwiczeń

- Wprowadzenie do R i Rstudio + dokumentacja
- Zarządzanie danymi (typy zmiennych, obiekty, import danych, manipulacja danymi)
- Statystyki opisowe
- Rozkłady prawdopodobieństwa zmiennej losowej
- Estymacja punktowa
- Estymacja przedziałowa
- Wprowadzenie do regresji liniowej

Czym jest statystyka?


- Dziedzina matematyki zajmująca się zbieraniem, analizę, wizualizacją i interpretacją danych
- Dwa działy: statystyka opisowa i wnioskowanie statystyczne
- Dostarcza metod do ilościowej analizy otaczającej nas rzeczywistości

Czym jest statystyka?




<https://www.youtube.com/watch?v=4DruxASC1kM>

US spending on science, space, and technology
correlates with
Suicides by hanging, strangulation and suffocation



Divorce rate in Maine correlates with Per capita consumption of margarine



Pakiety statystyczne

- SPSS (Statistical Package for the Social Sciences)
- Statistica
- Stata
- MATLAB
- GAUSS
- E Views
- **R**

Środowisko R

- Wywodzi się z języka S opracowanego na potrzeby analizy danych
- Własne czasopismo “R Journal”
- Używany na wielu uniwersytetach (np. MIT, Cambridge)
- Używany w wielu firmach (np. Google, CitiBank, Novartis)

Data Science Scientific Programmer

Bristol-Myers Squibb - Hopewell, NJ

At least 2 years programming experience in public health data sets preferred. As a member of this team, you will integrate data from diverse clinical trial and...

Estimated: \$120,000 - \$160,000 a year ⓘ

Data Scientist

Microsoft - Redmond, WA

Experience with a numerical programming language such as Python/Numpy/Scipy, R, Matlab, or similar and some familiarity with SQL or similar....

Estimated: \$77,000 - \$110,000 a year ⓘ

13d

Data Scientist III (Bioinformatics/Data Analytics)

Bio-Rad - Pleasanton, CA

Experienced with one major programming language (e.g. 3+ years proven leadership experience, managing Data Scientists and Statisticians....

Estimated: \$130,000 - \$170,000 a year ⓘ

Data Scientist/Statistician/Predictive Modeler

DataLab USA - Germantown, MD

Programming with SQL. R experience a plus. DataLab USA is an award winning database marketing company that focuses on optimizing multichannel

Zalety R

- Darmowy i dostępny na wszystkie platformy
- Otwarty kod źródłowy
- Szybki, elastyczny i stabilny
- Duże możliwości graficzne
- Duża liczba tutoriali i system pomocy
- Możliwość instalacji dodatkowych pakietów

Wady R

- Ograniczony interfejs graficzny
- Brak komercyjnego wsparcia technicznego
- Przechowywanie danych w pamięci fizycznej
- Konieczność nauki języka (+)